



UNIVERSIDAD AUTONOMA DE NUEVO LEON



**Facultad de Ciencias Físico Matemáticas
(FCFM)**

**Unidad de Aprendizaje:
Minería de Datos**

**Actividad 04
Pruebas Estadísticas**

Nombre:	Andrés Castro Hernandez
Matricula:	2069855
Grupo:	031
Profesor:	José Anastacio Hernandez Saldaña
Carrera:	LCC

Monterrey N.L. a; septiembre de 2026

4 - Pruebas Estadísticas

En las actividades anteriores hemos utilizado diferentes herramientas estadísticas y visualizaciones para analizar el comportamiento de LaLiga durante el periodo estudiado de 15 temporadas (2011-2026). A partir de estos análisis pudimos observar que la distribución de los equipos dentro de la clasificación no es completamente uniforme, ya que existe una presencia constante de determinados clubes en la parte alta, mientras que otros equipos consiguen alcanzar posiciones superiores en algunas temporadas, aunque no siempre logran mantenerse en ellas. Además, identificamos que la movilidad y las diferencias de puntos entre los equipos cambian de una temporada a otra, lo que nos permite considerar que la competitividad de la liga no se comporta de la misma manera en todas sus zonas.

En esta actividad buscamos continuar con la investigación utilizando pruebas estadísticas que nos permitan profundizar en algunas de las diferencias observadas anteriormente. Para ello, retomaremos la división de la clasificación en cuatro zonas: 1.ª–5.ª, 6.ª–10.ª, 11.ª–15.ª y 16.ª–20.ª. Esta agrupación nos permitirá mantener una referencia común para comparar el rendimiento de los equipos desde diferentes perspectivas y estudiar si las diferencias entre las zonas también se reflejan en sus estadísticas.

En particular, analizaremos el rendimiento ofensivo mediante los goles a favor por partido, el rendimiento defensivo a partir de los goles en contra por partido y la diferencia de goles como una medida conjunta de ambos aspectos. Mediante estas variables buscamos identificar si existen diferencias estadísticamente significativas entre las zonas y observar cómo se relacionan con la posición final de los equipos. De esta manera, no nos limitaremos a estudiar cuánto marcan los clubes, sino también cuánto reciben y qué balance obtienen al finalizar cada temporada.

Por otro lado, también ampliaremos el análisis hacia la competitividad dentro de cada zona, utilizando la distribución de los puntos obtenidos por los equipos y su variación a lo largo de las temporadas. Esto nos permitirá observar si los equipos que terminan en posiciones cercanas presentan rendimientos similares o si existen diferencias importantes entre ellos. Desde el contexto futbolístico, estas zonas se relacionan con distintos objetivos deportivos, como luchar por los primeros puestos, buscar el acceso a competiciones europeas, mantenerse en una posición intermedia o evitar el descenso. Sin embargo, utilizaremos estas referencias como contexto para interpretar los resultados, sin asumir que las posiciones finales permiten reconstruir por sí solas el desarrollo de la competencia durante toda la temporada.


De esta manera, esta actividad representa una continuación de los análisis anteriores: mientras que en las prácticas previas utilizamos estadísticas descriptivas y visualizaciones para identificar y describir patrones, en esta etapa incorporamos pruebas estadísticas para evaluar las diferencias entre las zonas y complementamos ese enfoque con el estudio de la dispersión de los puntos. Con ello buscamos obtener una visión más amplia de la estructura competitiva de LaLiga, reconociendo tanto los patrones que aparecen en los datos como las limitaciones que deben considerarse al interpretarlos.

4.1 – Rendimiento Ofensivo según la zona de clasificación.

En este primer análisis buscamos investigar si existen diferencias en el rendimiento ofensivo de los equipos dependiendo de la zona en la que terminan la clasificación de LaLiga. Una idea bastante común en el fútbol es que los equipos que ocupan los primeros puestos suelen tener una mayor capacidad goleadora, mientras que aquellos que terminan en posiciones inferiores pueden presentar más dificultades para marcar. Sin embargo, en lugar de asumir que este comportamiento ocurre de la misma manera en todas las temporadas, queremos utilizar nuestros datos para observar qué tan marcadas son estas diferencias y si encontramos evidencia estadística que las respalde.

Para realizar la comparación utilizamos los goles a favor por partido, calculados al dividir los goles anotados por cada equipo entre los 38 encuentros disputados durante una temporada. De esta manera, expresamos el rendimiento ofensivo en una misma escala y podemos comparar los registros de las 15 temporadas estudiadas. Posteriormente, agrupamos los datos en cuatro zonas de clasificación: del primero al quinto lugar, del sexto al décimo, del undécimo al decimoquinto y del decimosexto al vigésimo. Cada grupo contiene 75 registros equipo-temporada, lo que nos permite comparar el comportamiento ofensivo de los equipos según su posición final.

Una vez preparados los datos, utilizamos la prueba de Kruskal-Wallis para evaluar si existen diferencias estadísticamente significativas entre las cuatro zonas. Elegimos esta técnica porque, durante las revisiones previas, encontramos problemas relacionados con la normalidad de los datos y la igualdad de varianzas, por lo que consideramos conveniente recurrir a una prueba basada en rangos. El resultado de esta prueba nos permite evaluar si las distribuciones de los grupos presentan diferencias, aunque no identifica por sí solo entre qué zonas se encuentran. Por esta razón, también aplicamos las comparaciones posteriores de Dunn con la corrección de Holm, que nos permiten examinar los pares de zonas y determinar dónde aparecen diferencias estadísticamente significativas.



Al observar la gráfica, podemos identificar una disminución progresiva del rendimiento ofensivo conforme avanzamos hacia la parte baja de la clasificación. Los equipos que terminan entre los primeros cinco lugares presentan una media de 1.96 goles a favor por partido y una mediana de 1.82, mientras que, en las zonas del sexto al décimo, del undécimo al decimoquinto y del decimosexto al vigésimo lugar las medias disminuyen a 1.27, 1.13 y 0.98, respectivamente. Además, la zona alta presenta una mayor dispersión, lo que indica que existen diferencias importantes entre los propios equipos de estas posiciones. También encontramos valores atípicos en la zona del undécimo al decimoquinto lugar, lo que muestra que algunos equipos pueden mantener una producción goleadora superior a la habitual de su grupo sin necesariamente terminar en una posición más alta. Esto podría relacionarse con otros aspectos de su rendimiento, aunque la gráfica por sí sola no permite determinar las causas.

Para evaluar estas diferencias aplicamos la prueba de Kruskal-Wallis, con la que obtuvimos un estadístico de ($H=186.5614$) y un valor ($p=3.376 \times 10^{-40}$), considerablemente inferior al nivel de significancia de 0.05. Por ello, rechazamos la hipótesis nula y encontramos evidencia estadística de diferencias entre las distribuciones de las cuatro zonas. Posteriormente, las comparaciones de Dunn con la corrección de Holm mostraron diferencias significativas en los seis pares de grupos posibles. Esto indica que las diferencias no se limitan a los extremos de la clasificación, sino que también aparecen entre las zonas intermedias. Las tablas completas de estas comparaciones se conservan en Excel para su consulta.


Desde el contexto futbolístico, los resultados coinciden con la percepción de que los equipos que terminan en la parte alta de LaLiga suelen presentar una mayor capacidad goleadora. Sin embargo, marcar más goles no garantiza por sí solo una mejor clasificación, ya que también intervienen los goles recibidos y la capacidad de convertir los resultados en puntos. Por ello, encontramos una asociación entre el rendimiento ofensivo y la posición final, pero no podemos afirmar que los goles sean la única causa de estas diferencias. Además, como algunos clubes aparecen en varias temporadas, los registros no son completamente independientes, por lo que debemos interpretar los resultados con cautela. Aun así, este análisis nos proporciona una base para estudiar si las diferencias observadas en ataque también se reflejan en el rendimiento defensivo de los equipos.

4.2 – Rendimiento Defensivo según la zona de clasificación

En este segundo análisis buscamos investigar si existen diferencias en el rendimiento defensivo de los equipos dependiendo de la zona en la que terminan la clasificación de LaLiga. En el fútbol, una idea bastante común es que los equipos que ocupan los primeros puestos suelen destacar por su capacidad para evitar goles, mientras que aquellos que terminan en las posiciones inferiores pueden presentar mayores dificultades para mantener su portería protegida. Sin embargo, queremos observar qué tan marcadas son estas diferencias a lo largo de las temporadas estudiadas y si encontramos evidencia estadística que respalde este comportamiento.

Para realizar la comparación utilizamos los goles en contra por partido, calculados al dividir los goles recibidos por cada equipo entre los 38 encuentros disputados durante una temporada. De esta manera, expresamos el rendimiento defensivo en una misma escala y podemos comparar los registros de las 15 temporadas analizadas. Posteriormente, agrupamos los datos en las mismas cuatro zonas de clasificación: del primero al quinto lugar, del sexto al décimo, del undécimo al decimoquinto y del decimosexto al vigésimo. Cada grupo contiene 75 registros equipo-temporada, lo que nos permite examinar cómo cambia el comportamiento defensivo de acuerdo con la posición final de los equipos.

Una vez preparados los datos, utilizamos nuevamente la prueba de Kruskal-Wallis para evaluar si existen diferencias estadísticamente significativas entre las cuatro zonas. Al igual que en el análisis anterior, elegimos esta técnica porque las revisiones previas mostraron problemas relacionados con la normalidad de los datos y la igualdad de varianzas. Además, aplicamos las comparaciones posteriores de Dunn con la corrección de Holm para identificar entre qué pares de zonas aparecen diferencias significativas. De esta manera, no solo buscamos reconocer si existe una diferencia general en el rendimiento defensivo, sino también examinar cómo se comportan los grupos entre sí.



Al observar la gráfica, podemos identificar una tendencia progresiva en la que aumenta la cantidad de goles recibidos por partido conforme descendemos hacia las últimas posiciones de la clasificación. Los equipos que terminan entre los primeros cinco lugares presentan una media cercana a 0.97 goles en contra por partido y una mediana de aproximadamente 0.97, mientras que, en las zonas del sexto al décimo, del undécimo al decimoquinto y del decimosexto al vigésimo lugar, las medias aumentan a 1.28, 1.45 y 1.63, respectivamente. También podemos observar que la última zona presenta una mayor dispersión en sus resultados y algunos valores atípicos, mientras que en la zona del undécimo al decimoquinto lugar aparecen varios registros que se alejan del comportamiento habitual del grupo. Esto nos muestra que, aunque existe una tendencia general, el rendimiento defensivo no se comporta exactamente de la misma manera entre todos los equipos de una zona.

Para evaluar estas diferencias aplicamos la prueba de Kruskal-Wallis, con la que obtuvimos un estadístico de ($H=167.7909$) y un valor ($p=3.815 \times 10^{-36}$), considerablemente inferior al nivel de significancia de 0.05. Por ello, rechazamos la hipótesis nula y encontramos evidencia estadística de diferencias entre las distribuciones de las cuatro zonas. Posteriormente, las comparaciones de Dunn con la corrección de Holm mostraron diferencias significativas en los seis pares de grupos posibles. Esto indica que las diferencias observadas no se limitan únicamente a los equipos de los extremos de la clasificación, sino que también aparecen entre las zonas intermedias. Las tablas completas de estas comparaciones se conservan en Excel para su consulta.


Desde el enfoque futbolístico, estos resultados nos ayudan a reforzar la importancia del rendimiento defensivo para competir en LaLiga. Los equipos que reciben menos goles pueden tener mayores posibilidades de conservar ventajas y sumar puntos, mientras que las dificultades para defender pueden complicar sus resultados a lo largo de una temporada. Asimismo, la mayor dispersión observada en la última zona sugiere que existen diferencias importantes entre los propios equipos que terminan en esas posiciones. Sin embargo, no podemos afirmar que la defensa sea la única causa de la clasificación final, ya que también intervienen la capacidad ofensiva y otros factores del juego. Además, como algunos clubes aparecen en varias temporadas, los registros no son completamente independientes, por lo que debemos interpretar los resultados con cautela. A partir de este análisis, podemos avanzar al estudio de la diferencia de goles, una medida que nos permitirá integrar el rendimiento ofensivo y defensivo para observar de manera más completa el desempeño de los equipos.

4.3 – Diferencia de goles según la zona de clasificación

Este análisis se complementa de los dos anteriores, aquí buscamos investigar si existen diferencias en el balance de goles de los equipos dependiendo de la zona en la que terminan la clasificación de LaLiga. A diferencia de los análisis anteriores, en los que estudiamos por separado los goles anotados y recibidos, en esta ocasión queremos observar ambos aspectos de manera conjunta. En el fútbol, mantener una diferencia positiva entre los goles a favor y en contra suele ser una característica de los equipos que consiguen mejores resultados, mientras que una diferencia negativa puede reflejar dificultades para competir durante una temporada. Por ello, nos interesa comprobar qué tan marcadas son estas diferencias entre las distintas zonas de clasificación.

Para realizar la comparación utilizamos la diferencia de goles por partido, calculada al restar los goles en contra de los goles a favor y dividir el resultado entre los 38 encuentros disputados durante cada temporada. De esta manera, obtenemos una medida que permite identificar si un equipo anota más goles de los que recibe o si sucede lo contrario. Posteriormente, agrupamos los datos en las cuatro zonas utilizadas en los análisis anteriores: del primero al quinto lugar, del sexto al décimo, del undécimo al decimoquinto y del decimosexto al vigésimo. Cada grupo contiene 75 registros equipo-temporada, lo que nos permite comparar el balance goleador a lo largo de las 15 temporadas estudiadas.

Una vez preparados los datos, aplicamos la prueba de Kruskal-Wallis para evaluar si existen diferencias estadísticamente significativas entre las cuatro zonas. Mantuvimos esta técnica debido a los problemas de normalidad e igualdad de varianzas identificados durante las revisiones previas. Además, utilizamos las comparaciones posteriores de Dunn con la corrección de Holm para identificar entre qué pares de zonas aparecen diferencias significativas. Con ello buscamos determinar si el balance goleador cambia progresivamente según la posición final o si las diferencias se concentran únicamente entre determinados grupos.



Al observar la gráfica, podemos identificar una separación bastante marcada entre las cuatro zonas. Los equipos que terminan entre los primeros cinco lugares presentan una media de aproximadamente 0.99 goles de diferencia por partido y una mediana de 0.92, lo que indica un balance generalmente positivo. En la zona del sexto al décimo lugar, la media se aproxima a cero, mientras que en las zonas del undécimo al decimoquinto y del decimosexto al vigésimo lugar las medias descienden a -0.32 y -0.65, respectivamente. También podemos observar que la primera zona presenta una mayor dispersión, con equipos que alcanzan diferencias de goles muy positivas, mientras que en las zonas inferiores predominan los valores negativos. Aunque aparecen algunos valores atípicos, el patrón general muestra que el balance entre goles anotados y recibidos se deteriora conforme descendemos en la clasificación.


Para evaluar estas diferencias aplicamos la prueba de Kruskal-Wallis, con la que obtuvimos un estadístico de ($H=242.4788$) y un valor ($p=2.770 \times 10^{-52}$), considerablemente inferior al nivel de significancia de 0.05. Por ello, rechazamos la hipótesis nula y encontramos evidencia estadística de diferencias entre las distribuciones de las cuatro zonas. Posteriormente, las comparaciones de Dunn con la corrección de Holm mostraron diferencias significativas en los seis pares de grupos posibles, incluidas las zonas intermedias. Esto indica que las diferencias en el balance goleador no aparecen únicamente al comparar los primeros puestos con los últimos, sino que también se observan entre grupos cercanos de la clasificación. Las tablas completas de resultados se conservan en el archivo de Excel correspondiente.

Desde el punto de vista que nos da conocer los dos análisis anteriores, y los demás factores intrínsecos al deporte y a este tipo de competencias, estos resultados permiten integrar los resultados arrojados y los anteriormente obtenidos para continuar con nuestro estudio sobre el comportamiento de la liga. Los equipos de la zona alta no solo suelen anotar más goles y recibir menos, sino que también presentan un balance goleador claramente positivo. En cambio, las zonas inferiores muestran un balance negativo, lo que sugiere que, a lo largo de las temporadas estudiadas, estos equipos tienden a recibir más goles de los que consiguen marcar. La diferencia de goles, por tanto, parece ser una medida útil para distinguir el rendimiento de los equipos según su posición final. Sin embargo, no debemos interpretarla como una explicación única de la clasificación, ya que dos equipos con balances similares pueden obtener distintos puntos según cómo se distribuyan sus goles entre victorias, empates y derrotas. Con esto concluimos el análisis de las diferencias de rendimiento entre zonas y podemos continuar con el estudio de la competitividad, donde observaremos cómo se distribuyen los puntos entre los equipos de cada zona a lo largo de las temporadas.

4.4 – Competitividad y dispersión de puntos dentro de las zonas de clasificación

Para este análisis buscamos estudiar la competitividad de LaLiga desde una perspectiva diferente a la de los apartados anteriores. Hasta ahora hemos comparado el rendimiento ofensivo, defensivo y la diferencia de goles de los equipos según su posición final. Sin embargo, estas medidas no nos permiten observar directamente cómo se distribuyen los puntos entre los clubes que terminan en posiciones cercanas. Por ello, en esta ocasión queremos analizar qué tan agrupados o separados terminan los equipos dentro de cada zona y cómo cambia esta distribución entre temporadas. Esto nos permitirá explorar algunas diferencias entre la lucha por los primeros puestos, la competencia en la zona media y la permanencia, considerando que cada una representa objetivos deportivos distintos.


Para realizar este análisis agrupamos los equipos de cada temporada en las mismas cuatro zonas: del primero al quinto lugar, del sexto al décimo, del undécimo al decimoquinto y del decimosexto al vigésimo. Para cada grupo y temporada calculamos la desviación estándar, el rango intercuartílico (RIC) y el rango de puntos. La desviación estándar nos permite observar cuánto se alejan los registros respecto a la media del grupo; el RIC muestra la amplitud del 50 % central de los equipos, y el rango representa la diferencia entre el equipo con más puntos y el de menos puntos. Posteriormente, comparamos estas medidas entre las 15 temporadas estudiadas, lo que nos permite distinguir tanto los patrones generales de cada zona como las temporadas en las que la distribución de puntos fue particularmente diferente.



Al observar la primera gráfica, encontramos diferencias importantes entre las cuatro zonas. La zona del primero al quinto lugar presenta la mayor dispersión de puntos, con una desviación estándar media de aproximadamente 11.60 puntos por temporada, un RIC medio de 14.53 y un rango medio de 27.60 puntos. Esto sugiere que los equipos que terminan en la parte alta no forman necesariamente un grupo homogéneo: aunque todos ocupan posiciones destacadas, pueden existir diferencias considerables entre quienes dominan la clasificación y quienes completan los últimos puestos de esa zona. Desde el contexto futbolístico, esto podría reflejar temporadas en las que uno o varios clubes mantienen una ventaja amplia sobre sus perseguidores, mientras otros equipos deben competir por asegurar posiciones europeas. No obstante, la dispersión por sí sola no permite determinar si la pelea por el campeonato o por cada puesto estuvo cerrada, ya que para ello también necesitaríamos examinar las distancias específicas entre posiciones y la evolución de los puntos durante la temporada.

En contraste, la zona del undécimo al decimoquinto lugar presenta la menor dispersión, con una desviación estándar media de 2.51 puntos, un RIC medio de 3.40 y un rango medio de 5.60 puntos. Estos resultados indican que, al finalizar las temporadas, los equipos de esta zona suelen terminar relativamente agrupados en términos de puntos. Una posible interpretación es que existe un conjunto de clubes con resultados finales similares, sin que necesariamente se produzcan grandes diferencias entre ellos. Sin embargo, no debemos confundir esta cercanía en la clasificación final con una ausencia de competencia: dos equipos pueden terminar separados por pocos puntos después de haber seguido trayectorias muy distintas durante el año. Por su parte, la zona del sexto al décimo lugar presenta valores intermedios, con una desviación estándar media de 4.53 puntos, un RIC medio de 5.93 y un rango medio de 10.67. Esto sugiere una separación mayor que en la zona media-baja, posiblemente compatible con la convivencia de equipos que se acercan a los puestos superiores y otros que quedan más rezagados, aunque esta interpretación debe contrastarse con las distancias concretas de cada temporada.

La zona del decimosexto al vigésimo lugar también merece especial atención, ya que presenta una desviación estándar media de 6.13 puntos, un RIC medio de 6.87 y un rango medio de 14 puntos. Aunque sus valores son inferiores a los de la zona alta, muestran que las diferencias entre los equipos de las últimas posiciones pueden ser considerables. En términos futbolísticos, esto resulta relevante porque la zona incluye tanto a equipos que pueden conseguir la permanencia como a los que terminan descendiendo. La distribución de puntos puede reflejar situaciones muy distintas: clubes que se mantienen cerca entre sí en la lucha por evitar el descenso o equipos que terminan con una desventaja considerable respecto a sus rivales. En este sentido, la variabilidad de los puntos finales nos ayuda a identificar que la zona baja no siempre se comporta como un bloque uniforme. Aun así, para determinar qué tan ajustada estuvo la lucha por la permanencia sería necesario observar las distancias entre los puestos de salvación y descenso en cada temporada, no únicamente la dispersión del grupo completo.



La evolución temporal permite profundizar en estas diferencias, ya que muestra que la dispersión no permanece constante. En la zona alta observamos valores generalmente elevados, aunque con fluctuaciones importantes entre temporadas: la desviación estándar alcanza aproximadamente 20.68 puntos en 2011-12 y presenta otros repuntes en temporadas como 2015-16 y 2025-26. Esto sugiere que la separación entre los equipos de los primeros cinco puestos cambia considerablemente según la temporada. En la zona media-alta, los valores suelen mantenerse en niveles más moderados, pero también existen aumentos y descensos que reflejan cambios en la distribución final de puntos. La zona media-baja, por su parte, presenta una dispersión generalmente reducida, aunque registra incrementos puntuales, como en 2014-15 y 2019-20. Finalmente, la zona baja muestra las fluctuaciones más visibles después de la zona alta, con repuntes importantes en 2017-18, 2023-24 y 2024-25. Estas variaciones indican que las diferencias entre los equipos de las últimas posiciones no son iguales en todas las temporadas y que, en algunos años, la clasificación final presenta una separación mucho más amplia que en otros.

En conjunto, los resultados muestran que la competitividad no se distribuye de la misma manera en todas las zonas de LaLiga. La parte alta concentra las mayores diferencias de puntos, lo que resulta compatible con la presencia de equipos que terminan con ventajas amplias frente a otros clubes de su mismo grupo. La zona media-baja es la más compacta, mientras que la zona baja presenta una variabilidad intermedia y cambios considerables entre temporadas. Estos patrones nos permiten plantear que la competencia por el campeonato, los puestos europeos y la permanencia puede adoptar formas distintas, aunque no podemos determinar únicamente con estas medidas cuál de esas luchas fue más intensa o emocionante. También debemos recordar que las zonas se definieron a partir de la posición final, por lo que el análisis describe cómo quedaron distribuidos los puntos al cierre de cada temporada, no cómo evolucionó la incertidumbre jornada a jornada. Finalmente, estos resultados complementan los análisis anteriores al mostrar que las diferencias de rendimiento entre zonas no son el único aspecto relevante: también importa la distancia que separa a los equipos que terminan compartiendo una misma parte de la clasificación.