UNIVERSIDAD AUTONOMA DE NUEVO LEON

Facultad de Ciencias Físico Matemáticas

(FCFM)

Unidad de Aprendizaje:

Minería de Datos

Actividad 05

Modelos Lineales y Correlación

Nombre: Andrés Castro Hernandez

Matricula: 2069855

Grupo: 031

Profesor: José Anastacio Hernández Saldaña

Carrera: LCC

Monterrey N.L. a; octubre de 2026

5 - Modelos Lineales y Correlación

Los modelos lineales y el análisis de correlación son herramientas estadísticas que permiten estudiar la relación entre distintas variables y comprender en qué medida los cambios en una de ellas se asocian con los de otra. Mediante la regresión lineal podemos representar estas relaciones a través de una ecuación, mientras que el coeficiente de determinación (R^2) nos permite evaluar qué proporción de la variación de una variable puede explicar el modelo a partir de las variables consideradas.

En esta práctica aplicaremos estas herramientas al análisis de LaLiga, utilizando los datos de las temporadas comprendidas entre 2011-12 y 2025-26. Buscaremos estudiar la relación entre los goles a favor, los goles en contra y los puntos obtenidos por los equipos, mediante tres modelos lineales que nos permitirán analizar el rendimiento ofensivo, el defensivo y la combinación de ambos.

Con ello, esperamos identificar qué tan estrechamente se relaciona cada dimensión del rendimiento con los puntos obtenidos y si su análisis conjunto permite comprender mejor las diferencias entre los equipos. De esta manera, buscamos aportar una perspectiva complementaria a nuestra investigación sobre la competitividad de LaLiga, considerando tanto los perfiles de los equipos que luchan por el campeonato como los de aquellos que terminan en las posiciones más bajas de la clasificación.

Selección de las variables de estudio

Para realizar el análisis, tomamos como referencia los registros de clasificación final de las 15 temporadas de LaLiga comprendidas entre 2011-12 y 2025-26. Esto nos proporciona información de 300 registros equipo-temporada, correspondientes a los 20 equipos que participan en cada edición de la competición. A partir de estos datos, seleccionamos los puntos obtenidos, los goles a favor y los goles en contra como las variables principales del estudio.

La elección de los puntos como variable objetivo responde a que constituyen el criterio utilizado para ordenar a los equipos en la clasificación. Aunque los goles permiten describir distintos aspectos del rendimiento, son los puntos los que determinan la posición final de cada equipo. Por ello, buscamos estudiar en qué medida las estadísticas ofensivas y defensivas se relacionan con la obtención de puntos a lo largo de las temporadas analizadas.

Como primera variable, seleccionamos los goles a favor, debido a que representan la capacidad ofensiva de un equipo para convertir sus oportunidades en anotaciones. Desde una perspectiva futbolística, esperamos encontrar una relación positiva entre esta variable y los puntos obtenidos: los equipos que marcan más goles suelen contar con mayores posibilidades de ganar partidos, aunque la cantidad de goles por sí sola no determina el resultado de cada encuentro.

Por otro lado, incorporamos los goles en contra como una medida del comportamiento defensivo. Esta variable permite analizar la relación entre los goles que recibe un equipo y su rendimiento en la clasificación. En este caso, esperamos una relación negativa, ya que conceder menos goles suele facilitar la obtención de victorias y empates. Sin embargo, consideramos que el rendimiento defensivo no debe interpretarse únicamente como una característica de la línea defensiva, pues también puede reflejar aspectos colectivos, como la presión, la posesión del balón o la capacidad del equipo para controlar los partidos.

Con estas variables seleccionadas, decidimos expresarlas en función de los partidos, con los goles a favor, goles en contra y puntos por partido. Aquí queremos mantener una escala comparable entre las variables y facilitar la interpretación de los resultados mediante valores que representen el rendimiento promedio de cada equipo durante una temporada, es decir, queremos ver si estos parámetros se relacionan o son realmente determinantes en el desempeño / destino que tuvieron los equipos en la temporada.

En nuestro conjunto de datos, las clasificaciones corresponden a temporadas completas de LaLiga, por lo que cada equipo disputa 38 partidos. En consecuencia, calculamos cada indicador dividiendo su valor acumulado entre 38. De esta manera, en lugar de comparar únicamente cantidades totales, podemos analizar cuántos goles marca, cuántos recibe y cuántos puntos obtiene un equipo, en promedio, por encuentro.

Esta transformación también facilita la interpretación de la ecuación de regresión, ya que permite expresar la relación entre las variables en términos del rendimiento por partido. Es importante señalar que, al utilizar temporadas completas con el mismo número de encuentros, esta normalización no cambia las diferencias relativas entre los equipos.

Diseño y comparación de los modelos lineales

En lugar de construir un único modelo, planteamos tres modelos lineales con el propósito de comparar la relación individual de cada variable con los puntos y evaluar si su combinación ofrece una representación más completa del rendimiento de los equipos.

El primer modelo relaciona los puntos por partido con los goles a favor por partido. Con él buscamos examinar la fuerza de la relación entre el rendimiento ofensivo y los puntos obtenidos, así como determinar qué tan bien esta variable representa las diferencias de rendimiento entre los equipos.

El segundo modelo relaciona los puntos por partido con los goles en contra por partido. Su finalidad es estudiar el comportamiento de la relación entre el rendimiento defensivo y los puntos, complementando la perspectiva ofensiva del primer modelo.

Finalmente, el tercer modelo incorpora simultáneamente los goles a favor y los goles en contra por partido. Esta decisión parte de que el rendimiento futbolístico no depende de una sola dimensión: un equipo puede destacar por su capacidad anotadora, por su solidez defensiva o por la combinación de ambas. Al considerar las dos variables dentro de una misma ecuación, buscamos evaluar si su análisis conjunto permite representar mejor las diferencias en los puntos obtenidos.

La comparación entre los tres modelos se realizará mediante el coeficiente de determinación (R^2), que utilizaremos para medir la proporción de la variabilidad de los puntos por partido que queda explicada por cada modelo en los datos analizados. Así podremos comparar el ajuste de las distintas alternativas sin asumir de antemano que una de ellas será necesariamente superior.

Además de hacer estas comparaciones con los modelos, decidimos examinar descriptivamente los perfiles de los equipos que terminaron como campeones y de aquellos que ocuparon los últimos tres puestos de la clasificación en cada temporada. Para ello, consideramos los 15 campeones y los 45 registros correspondientes a los equipos que finalizaron en las posiciones 18.ª, 19.ª y 20.ª (Recordemos que son los equipos que se van a segunda división al finalizar el torneo).

Cabe aclarar que esta comparación tiene un propósito descriptivo y complementario: no pretende establecer una fórmula universal para identificar campeones ni construir un sistema de predicción del descenso. Su función es contrastar los patrones observados en los modelos con perfiles competitivos reconocibles dentro de LaLiga y enriquecer la interpretación de los resultados dándole un enfoque mas apegado a lo que normalmente se ve en un análisis en el mundo de este deporte.

Preparación de los datos y organización del análisis

Para desarrollar esta práctica, partimos de la información recopilada y organizada durante la Práctica 2, en la que trabajamos con las clasificaciones finales de LaLiga. Decidimos reutilizar esta base de datos porque ya contenía las estadísticas necesarias para estudiar la relación entre los goles y los puntos obtenidos, por lo que no era necesario reconstruir información que ya habíamos procesado anteriormente. La base estaba organizada por temporada y equipo, con datos como la posición final, los puntos acumulados, los goles a favor y los goles en contra. En total, trabajamos con 300 registros correspondientes a los 20 equipos de cada una de las 15 temporadas analizadas.

Antes de realizar los cálculos, seleccionamos las columnas necesarias y comprobamos que no existieran valores faltantes ni registros duplicados para una misma combinación de temporada y equipo. Consideramos importante realizar esta revisión porque cualquier inconsistencia podía afectar los resultados o dificultar su interpretación. Posteriormente, transformamos las estadísticas acumuladas en promedios por partido, dividiendo los goles a favor, los goles en contra y los puntos entre los 38 encuentros de cada temporada. De esta manera, obtuvimos indicadores que permiten expresar el rendimiento promedio de cada equipo y facilitan la interpretación de las relaciones que buscamos estudiar.

También incorporamos una clasificación por zonas de la tabla, agrupando a los equipos según su posición final: del primero al quinto puesto, del sexto al décimo, del undécimo al decimoquinto y del decimosexto al vigésimo. Aunque estas categorías no intervienen directamente en el cálculo de las regresiones, decidimos utilizarlas para distinguir visualmente a los equipos según su ubicación en la clasificación. Así, nuestro análisis no se limita a identificar una tendencia general entre goles y puntos, sino que también permite observar cómo se distribuyen los equipos de distintas zonas dentro de esa relación.

Una vez preparada la información, organizamos el procesamiento para construir tres modelos lineales: uno que relaciona los goles a favor por partido con los puntos por partido, otro que estudia la relación entre los goles en contra y los puntos, y un tercero que incorpora ambas variables simultáneamente. Mantener los tres modelos dentro de un mismo procedimiento nos permite compararlos bajo un criterio común y examinar si la combinación del rendimiento ofensivo y defensivo representa mejor las diferencias observadas entre los equipos. Además de calcular las ecuaciones y el coeficiente de determinación (R^2), el programa obtiene las estimaciones de puntos y las diferencias entre los valores reales y estimados, información que utilizamos posteriormente para evaluar el ajuste de los modelos.

Para complementar este análisis, incorporamos el cálculo de correlaciones entre las variables y elaboramos resúmenes estadísticos por zonas de la clasificación. También realizamos una comparación descriptiva entre los campeones de cada temporada y los equipos que terminaron en los últimos tres puestos. Con ello buscamos relacionar los resultados de los modelos con perfiles competitivos concretos, considerando que los equipos situados en los extremos de la clasificación suelen presentar diferencias importantes en su rendimiento.

Una decisión importante fue organizar las salidas del programa en un archivo Excel dividido en hojas con un propósito en especial, en lugar de conservar todos los resultados únicamente en la consola o concentrarlos en una sola tabla. Consideramos que los valores numéricos adquieren mayor

utilidad cuando se presentan de acuerdo con la pregunta que buscamos responder. Por ello, destinamos una hoja a la comparación de los modelos, otra a sus coeficientes y otra a las correlaciones. Asimismo, organizamos los perfiles por zona y la comparación entre campeones y últimos tres puestos en hojas independientes, mientras que las estimaciones y los residuos del modelo conjunto se reúnen en otra para facilitar la revisión de sus diferencias respecto a los valores reales. Finalmente, conservamos una hoja con los datos analizados y las variables derivadas, lo que permite consultar la información utilizada en los cálculos. Esta estructura busca que el archivo no sea solamente un conjunto de cifras, sino una herramienta que facilite la comparación, la revisión y la interpretación de los resultados.

Además de las tablas, generamos cuatro gráficas para representar visualmente las relaciones estudiadas y evaluar el comportamiento del modelo conjunto. Las primeras dos muestran la relación entre los goles a favor y los puntos, y entre los goles en contra y los puntos, incorporando una recta de regresión que facilita observar la tendencia general. La tercera compara los puntos reales con los estimados por el modelo conjunto y utiliza una línea de referencia para identificar qué tan cerca se encuentran ambos valores. Finalmente, la cuarta representa los residuos del modelo en función de los puntos estimados, con el propósito de examinar la distribución de los errores y detectar posibles patrones que indiquen limitaciones en el ajuste.

Modelos Lineales Aplicados a nuestros datos.

Como primer paso, comparamos los tres modelos lineales construidos para estudiar la relación entre el rendimiento ofensivo, el defensivo y los puntos obtenidos por los equipos. Para ello, utilizamos el coeficiente de determinación ((R^2)), que nos permite evaluar qué proporción de la variabilidad de los puntos por partido queda representada por cada modelo dentro de los datos analizados.

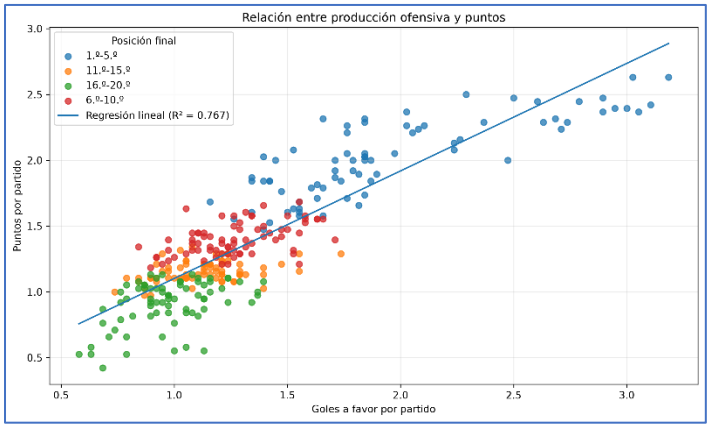
Modelo	Variables explicativas	(R^2)	Variabilidad representada
Modelo ofensivo	Goles a favor por partido	0.7667	76.67 %
Modelo defensivo	Goles en contra por partido	0.6138	61.38 %
Modelo conjunto	Goles a favor y en contra por partido	0.9239	92.39 %

El modelo ofensivo, que utiliza los goles a favor por partido como variable explicativa, obtuvo un (R^2) de 0.7667. Esto significa que el modelo representa aproximadamente el 76.67 % de la variabilidad observada en los puntos por partido. Por su parte, el modelo defensivo, basado en los goles en contra por partido, alcanzó un (R^2) de 0.6138, equivalente al 61.38 %. Aunque ambos resultados muestran relaciones importantes con el rendimiento en la clasificación, el modelo ofensivo presentó un mayor ajuste cuando se utilizó de manera individual.

Esta diferencia resulta interesante desde la perspectiva futbolística, ya que la capacidad de marcar goles está estrechamente relacionada con la posibilidad de conseguir victorias y, por tanto, acumular puntos. Sin embargo, esto no significa que la defensa tenga una importancia menor en el fútbol. Los goles recibidos también se relacionan con los resultados, pero su efecto puede manifestarse de distintas maneras según el comportamiento general del equipo y su capacidad para convertir sus oportunidades en goles.

Al combinar ambas variables en el tercer modelo, obtuvimos un (R^2) de 0.9239, por lo que el modelo representa aproximadamente el 92.39 % de la variabilidad de los puntos por partido. La mejora respecto a los modelos individuales sugiere que estudiar conjuntamente la producción ofensiva y los goles recibidos permite describir mejor las diferencias de rendimiento entre los equipos a lo largo de las temporadas analizadas.

Este resultado respalda la decisión de no limitar nuestro estudio a una sola dimensión del rendimiento. En una competición como LaLiga, los equipos pueden construir sus resultados mediante perfiles diferentes: algunos destacan por su capacidad goleadora, mientras que otros combinan una producción ofensiva más moderada con una menor cantidad de goles recibidos. El modelo conjunto permite incorporar estas dos dimensiones dentro de una misma representación estadística.



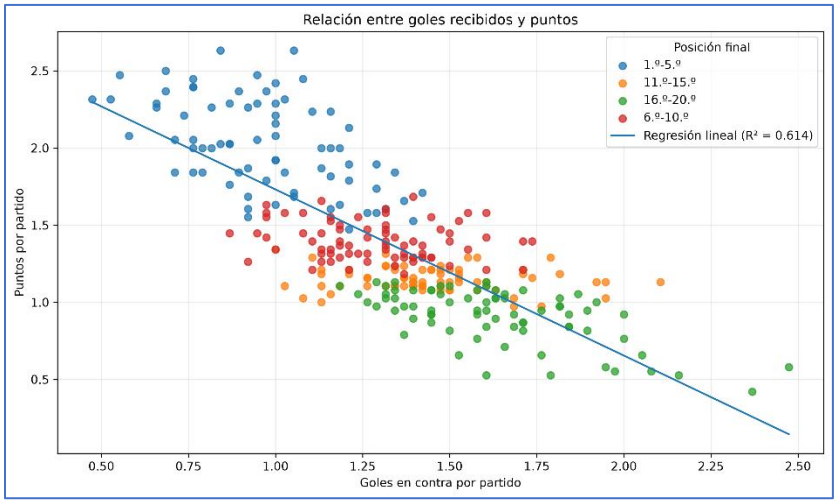
En esta primera gráfica analizamos la relación entre los goles a favor por partido y los puntos obtenidos por partido durante las 15 temporadas estudiadas. Para ello, utilizamos un diagrama de dispersión, en el que cada punto representa a un equipo en una temporada determinada. Además, distinguimos las observaciones según la zona de la clasificación final y añadimos una recta de regresión para identificar la tendencia lineal general.

La gráfica permite observar la relación positiva entre ambas variables: conforme aumenta el promedio de goles a favor, generalmente también aumenta el promedio de puntos obtenidos. Esta tendencia coincide con la lógica competitiva del fútbol, ya que una mayor capacidad anotadora suele facilitar la obtención de victorias. Sin embargo, la distribución de los puntos también permite reconocer que equipos con promedios ofensivos similares pueden terminar con cantidades distintas de puntos, por lo que marcar más goles no garantiza por sí solo un determinado rendimiento en la clasificación.

El coeficiente de determinación del modelo ofensivo fue de (R^2 = 0.7667), lo que indica que la relación lineal con los goles a favor representa aproximadamente el 76.67 % de la variabilidad observada en los puntos por partido. Este resultado muestra que la producción ofensiva constituye una variable estrechamente relacionada con el rendimiento de los equipos, aunque permanece una parte de la variabilidad que el modelo no representa.

Desde una perspectiva futbolística, esas diferencias pueden estar relacionadas con aspectos que no incorporamos directamente al modelo, como la distribución de los goles entre los partidos, la capacidad para mantener ventajas, la frecuencia de empates o el comportamiento defensivo. Por ejemplo, dos equipos pueden alcanzar un promedio goleador parecido, pero obtener resultados distintos si uno concentra sus anotaciones en determinados encuentros y el otro mantiene una producción más regular. Estas posibilidades sirven como contexto para interpretar la dispersión, aunque la gráfica por sí sola no permite determinar cuál de esos factores explica las diferencias observadas.

Por otra parte, la distinción por zonas de la clasificación permite examinar cómo se distribuyen los equipos según su posición final. Esperamos encontrar una mayor presencia de equipos de la parte alta entre los registros con mejores promedios ofensivos, mientras que en las zonas inferiores pueden aparecer equipos con una producción goleadora más limitada. Esta distribución ayuda a relacionar la tendencia estadística con la estructura competitiva de LaLiga, sin asumir que todos los equipos de una misma zona presentan un comportamiento idéntico.



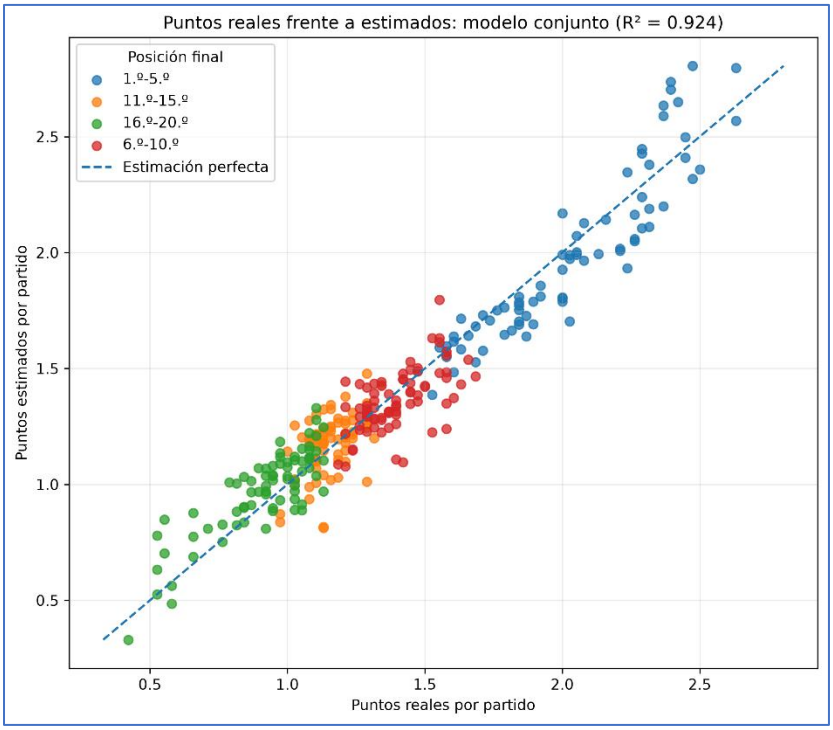
En esta segunda gráfica analizamos la relación entre los goles en contra por partido y los puntos obtenidos por partido. Al igual que en la visualización anterior, utilizamos un diagrama de dispersión, en el que cada punto representa a un equipo en una temporada, diferenciando las observaciones según la zona de la clasificación final. También incorporamos una recta de regresión para identificar la tendencia general entre ambas variables.

A diferencia de la gráfica anterior, en este caso encontramos una relación negativa, con un coeficiente de determinación de (R^2 = 0.6138) para el modelo defensivo. Esto indica que la relación lineal con los goles recibidos representa aproximadamente el 61.38 % de la variabilidad observada en los puntos por partido. En términos generales, los equipos que reciben menos goles tienden a obtener más puntos, mientras que aquellos que conceden una mayor cantidad suelen presentar un rendimiento inferior en la clasificación.

Desde una perspectiva futbolística, este comportamiento resulta coherente con la importancia de evitar goles en contra para conservar resultados favorables. Una defensa que permite pocas anotaciones puede facilitar que un equipo mantenga ventajas o consiga puntos incluso en encuentros en los que su producción ofensiva es limitada. Por el contrario, recibir muchos goles puede dificultar la obtención de resultados positivos, especialmente cuando el equipo no cuenta con una capacidad ofensiva suficiente para compensarlos.

Sin embargo, la relación observada no implica que todos los equipos con pocos goles recibidos obtengan necesariamente muchos puntos. En el fútbol, la distribución de las anotaciones también importa: un equipo puede mantener varios partidos sin recibir goles, pero tener dificultades para ganar si genera pocas oportunidades de ataque. De manera similar, un equipo con una producción ofensiva elevada puede compensar parcialmente sus problemas defensivos. Estas situaciones ayudan a comprender por qué la relación entre goles en contra y puntos, aunque importante, no representa por sí sola todas las diferencias de rendimiento.

Al distinguir las observaciones por zonas de la clasificación, buscamos identificar si los equipos de la parte alta tienden a concentrarse en valores bajos de goles recibidos y valores elevados de puntos, mientras que los de las zonas inferiores muestran una distribución diferente. Esta perspectiva permite relacionar el comportamiento defensivo con la estructura competitiva de LaLiga, sin asumir que la posición final depende exclusivamente de la defensa.

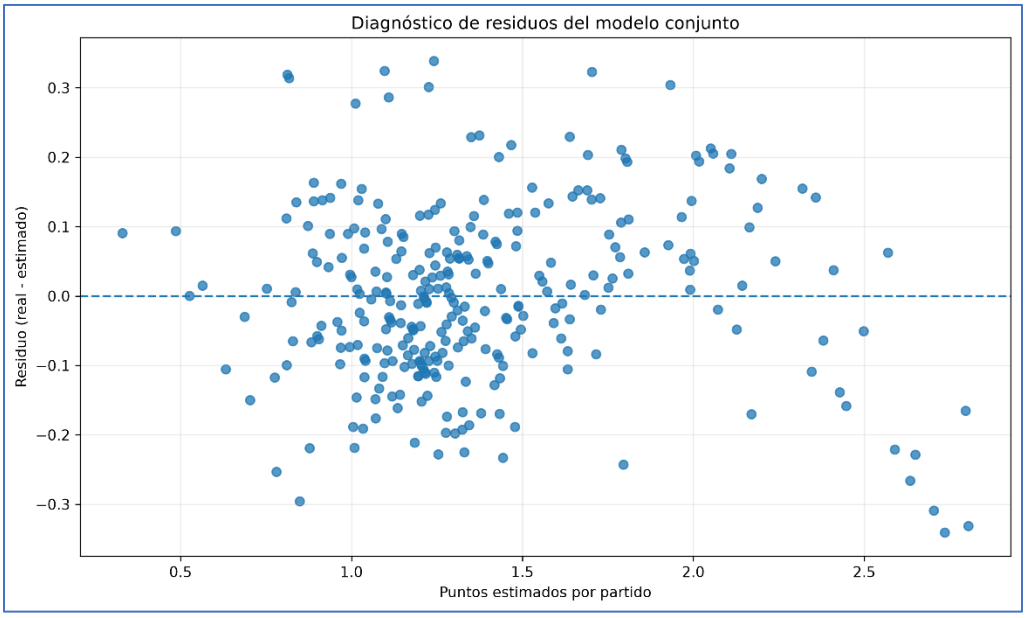


En esta tercera gráfica evaluamos el comportamiento del modelo conjunto mediante la comparación entre los puntos por partido registrados por cada equipo y los valores estimados por la ecuación de regresión. Para ello, utilizamos un diagrama de dispersión en el que cada observación representa un equipo en una temporada. Además, incorporamos una línea de referencia que representa una estimación perfecta, es decir, los casos en los que el valor estimado coincide exactamente con el valor real.

La principal utilidad de esta visualización es que nos permite observar de manera directa qué tan próximas se encuentran las estimaciones del modelo a los resultados registrados. Cuando una observación se encuentra cerca de la línea de referencia, la diferencia entre los puntos reales y estimados es pequeña; cuando se aleja de ella, el modelo presenta un error mayor para ese equipo y temporada. De esta manera, podemos complementar el coeficiente de determinación con una representación visual de la precisión de las estimaciones.

El modelo conjunto obtuvo un (R^2 = 0.9239), lo que indica que representa aproximadamente el 92.39 % de la variabilidad observada en los puntos por partido dentro de los datos analizados. Este resultado sugiere un ajuste elevado y es consistente con la expectativa de que considerar tanto los goles a favor como los goles en contra permite representar mejor el rendimiento que utilizar cada variable de manera individual.

Desde una perspectiva futbolística, comparar los valores reales y estimados resulta útil porque permite reconocer que los equipos no siempre obtienen exactamente los puntos que cabría esperar a partir de sus promedios goleadores. Las diferencias pueden reflejar particularidades en la distribución de los resultados, como la cantidad de victorias, empates y derrotas, que no se representan directamente mediante los promedios de goles utilizados en el modelo. Sin embargo, cabe aclarar que la gráfica no permite determinar por sí sola las causas de cada diferencia.



En esta cuarta gráfica analizamos los residuos del modelo conjunto, calculados como la diferencia entre los puntos reales y los puntos estimados por la regresión. Para ello, representamos los residuos en función de los puntos estimados por partido e incorporamos una línea horizontal en cero, que sirve como referencia para distinguir entre las estimaciones que quedaron por encima o por debajo de los valores reales.

La importancia de esta visualización radica en que un modelo no debe evaluarse únicamente por el valor de (R^2). Aunque esta métrica permite conocer qué proporción de la variabilidad de los puntos representa la ecuación, no muestra por sí sola cómo se distribuyen los errores. Por esta razón, decidimos revisar los residuos para complementar la evaluación del ajuste y observar si las diferencias entre los valores reales y estimados presentan algún comportamiento particular.

Cuando un residuo es positivo, significa que el equipo obtuvo más puntos de los que estimó el modelo; cuando es negativo, indica que obtuvo menos puntos de los estimados. Por ejemplo, un equipo podría presentar un residuo positivo si su rendimiento en términos de puntos fue superior al que sugerían sus promedios de goles a favor y en contra. De manera contraria, un residuo negativo indicaría que esos promedios no se tradujeron en tantos puntos como estimó la ecuación. Estas diferencias permiten reconocer casos que merecen una revisión más detallada, aunque no identifican por sí solas las causas de ese comportamiento.

Desde el punto de vista estadístico, también es importante observar si los residuos se distribuyen alrededor de la línea cero sin formar patrones evidentes. Una dispersión sin patrones claros sería compatible con un comportamiento adecuado de los errores respecto a los valores estimados, mientras que una estructura visible, una variación creciente o una concentración desigual podrían señalar aspectos que requieren una evaluación adicional.

Esta práctica nos ayuda a complementar los análisis realizados con anterioridad al incorporar modelos lineales y correlaciones para estudiar cómo se relacionan el rendimiento ofensivo y defensivo con los puntos obtenidos por los equipos. Mientras que en las prácticas anteriores nos enfocamos en describir las diferencias entre temporadas, zonas de la clasificación y trayectorias de los clubes, ahora buscamos representar estadísticamente estas relaciones y evaluar qué tan bien permiten comprender las diferencias de rendimiento observadas. Los resultados muestran que considerar conjuntamente los goles a favor y los goles en contra ofrecer una mejor representación de la variabilidad de los puntos que analizar cada variable por separado. Esto refuerza la idea de que la competitividad en LaLiga no puede comprenderse desde una única dimensión del juego, sino que requiere considerar distintos aspectos del rendimiento. De esta manera, continuamos construyendo una visión más amplia de la estructura competitiva de la competición, reconociendo al mismo tiempo que los resultados obtenidos representan patrones estadísticos y no una explicación completa de todos los factores que intervienen en el fútbol.