UNIVERSIDAD AUTONOMA DE NUEVO LEON

Facultad de Ciencias Físico Matemáticas

(FCFM)

Unidad de Aprendizaje:

Minería de Datos

Actividad 06

Clasificación de Datos

Nombre: Andrés Castro Hernandez

Matricula: 2069855

Grupo: 031

Profesor: José Anastacio Hernandez Saldaña

Carrera: LCC

Monterrey N.L. a; octubre de 2026

6 - Clasificación de Datos

El análisis del rendimiento de los equipos de LaLiga nos permite comprender mejor las diferencias que existen entre los clubes a lo largo de una competición. A través de sus estadísticas, es posible identificar características que ayudan a explicar por qué algunos equipos consiguen mantenerse en la parte alta de la clasificación, mientras que otros ocupan posiciones intermedias o luchan por evitar el descenso. Sin embargo, el comportamiento de los equipos no siempre sigue patrones claramente definidos, ya que clubes con características similares pueden terminar en posiciones diferentes. Esto abre la posibilidad de utilizar técnicas de minería de datos para identificar patrones en el rendimiento de los equipos y estudiar hasta qué punto estas características permiten distinguirlos.

Desde una perspectiva futbolística, podemos esperar que los equipos que ocupan los primeros puestos presenten características diferentes de aquellos que luchan por mantenerse en Primera División. No obstante, la separación entre las zonas de clasificación no siempre es clara, por lo que resulta necesario comprobar qué tan útiles son las estadísticas seleccionadas para reconocer los distintos perfiles de rendimiento y en qué situaciones pueden resultar insuficientes.

Para estudiar esta cuestión, utilizaremos el algoritmo de clasificación K vecinos más cercanos (KNN), que permite identificar similitudes entre los registros de los equipos y asignarles una categoría de acuerdo con las características de otros registros conocidos. En nuestro caso, agruparemos las posiciones finales en cuatro zonas: del primero al quinto lugar, del sexto al décimo, del undécimo al decimoquinto y del decimosexto al vigésimo. A partir de los datos de las 15 temporadas comprendidas entre 2011-12 y 2025-26, trabajaremos con los goles a favor y los goles en contra por partido para analizar qué tan bien permiten diferenciar estas categorías. También compararemos un modelo que incorpora la diferencia de goles para observar si añadir esta información mejora la clasificación.

De esta manera, abordaremos la competitividad de LaLiga desde una perspectiva complementaria al análisis descriptivo. En esta actividad, utilizaremos algunas de las características estadísticas del rendimiento de los equipos para construir un modelo capaz de clasificarlos según su zona final. Además de evaluar su desempeño, examinaremos los errores que comete y las zonas en las que presenta mayores dificultades, con el propósito de comprender tanto la utilidad de este enfoque como las limitaciones de representar el rendimiento futbolístico mediante un conjunto reducido de estadísticas.

Construcción del modelo

Para desarrollar este análisis, decidimos utilizar el algoritmo K vecinos más cercanos (KNN), una técnica de clasificación que permite asignar una categoría a un registro a partir de las características de otros registros similares. En nuestro caso, buscamos que el modelo reconozca patrones en el rendimiento de los equipos y los utilice para determinar a cuál de las cuatro zonas de la clasificación pertenece cada uno. La idea es que, si ciertos perfiles estadísticos aparecen con mayor frecuencia entre equipos que terminan en una zona determinada, el modelo pueda aprovechar esas similitudes para clasificar nuevos registros.

Como punto de partida, retomamos la división de la clasificación utilizada en las prácticas anteriores: del primero al quinto lugar, del sexto al décimo, del undécimo al decimoquinto y del decimosexto al vigésimo. Esta agrupación nos permite mantener una referencia común a lo largo de nuestra investigación y relacionar los resultados del modelo con los diferentes objetivos deportivos de LaLiga. Aunque los equipos de una misma zona no necesariamente presentan el mismo rendimiento, sus posiciones finales nos proporcionan una categoría que podemos utilizar para evaluar si las estadísticas seleccionadas permiten distinguirlos.

Para representar las características de cada equipo, seleccionamos los goles a favor y los goles en contra por partido. Los primeros nos permiten observar su capacidad anotadora, mientras que los segundos representan la cantidad de goles que reciben durante una temporada. Decidimos utilizar promedios por partido en lugar de las cantidades acumuladas, ya que así expresamos ambas variables en una escala comparable y mantenemos la misma lógica de análisis que empleamos en las prácticas anteriores. De esta manera, buscamos que el modelo identifique diferencias en los perfiles ofensivos y defensivos sin depender únicamente de los totales de goles.

Además de este primer modelo, construiremos una alternativa que incorpora la diferencia de goles por partido. Esta variable representa el balance entre los goles anotados y recibidos, por lo que nos permite resumir en un solo indicador parte de la información que ya contienen las dos variables anteriores. Al comparar ambos modelos, podremos observar si incorporar este balance aporta información útil para distinguir las zonas o si el modelo que utiliza únicamente los goles a favor y en contra obtiene resultados similares o mejores.

Una característica importante de KNN es que la clasificación depende del número de vecinos que se consideran para determinar la categoría de un registro. Un valor pequeño de (K) hace que la decisión dependa de un grupo reducido de equipos, mientras que un valor mayor incorpora un conjunto más amplio de referencias. Por esta razón, no elegiremos este parámetro de manera arbitraria, sino que evaluaremos diferentes valores y seleccionaremos el que presente el mejor desempeño durante la etapa de validación. También estandarizaremos las variables para evitar que las diferencias de escala influyan innecesariamente en el cálculo de las distancias entre registros.

Preparación de los datos y evaluación

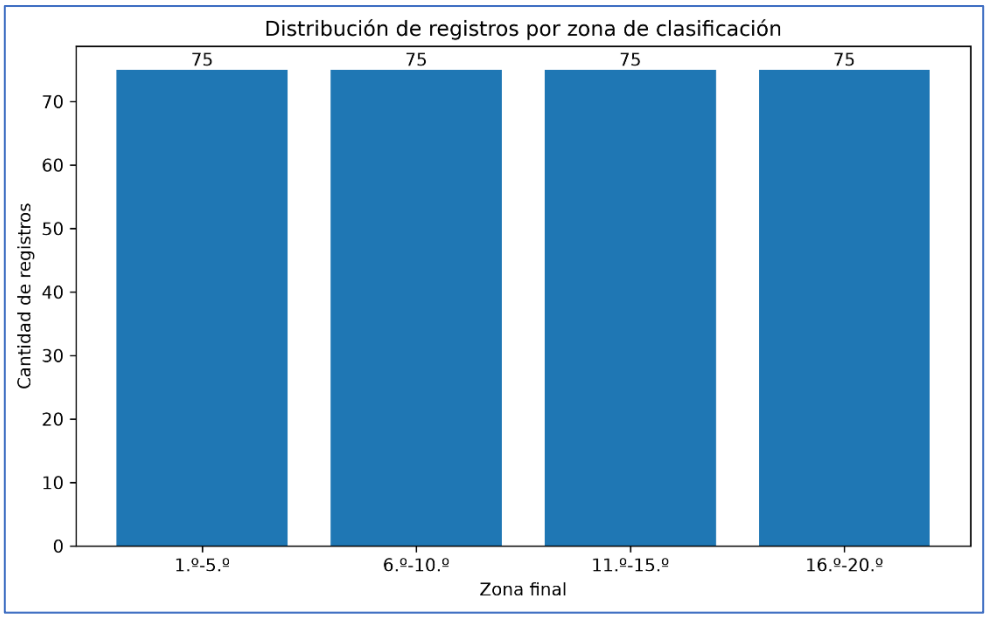
Para desarrollar el modelo, retomamos la base de datos de la Práctica 2, que contiene las clasificaciones finales de las 15 temporadas de LaLiga comprendidas entre 2011-12 y 2025-26. Trabajamos con 300 registros, correspondientes a los 20 equipos de cada temporada, y verificamos que no existieran valores faltantes ni registros duplicados por equipo y temporada.

A partir de los goles a favor y en contra, calculamos sus promedios por partido y construimos las cuatro zonas de clasificación. Posteriormente, organizamos los datos cronológicamente en tres conjuntos: diez temporadas para entrenamiento (200 registros), dos para validación (40 registros) y las tres más recientes para la prueba final (60 registros). Esta separación nos permite evaluar el modelo con temporadas que no participaron en su entrenamiento ni en la selección de sus parámetros.

Para elegir el número de vecinos, evaluamos valores impares de (K) entre 1 y 25, utilizando el F1 macro como criterio principal. El modelo base seleccionó (K=17), mientras que el modelo alternativo, que incorpora la diferencia de goles por partido, seleccionó (K=23). También estandarizamos las variables para que sus escalas no influyeran inadecuadamente en las distancias calculadas por KNN.

Para esto, reservamos las tres últimas temporadas para evaluar el desempeño de ambos modelos. De esta manera, buscamos comprobar qué tan bien pueden reconocer las zonas de clasificación en temporadas posteriores, teniendo presente que algunos equipos aparecen en diferentes temporadas y que el análisis no evalúa necesariamente el comportamiento de clubes completamente nuevos.

Distribución de los equipos según su zona final

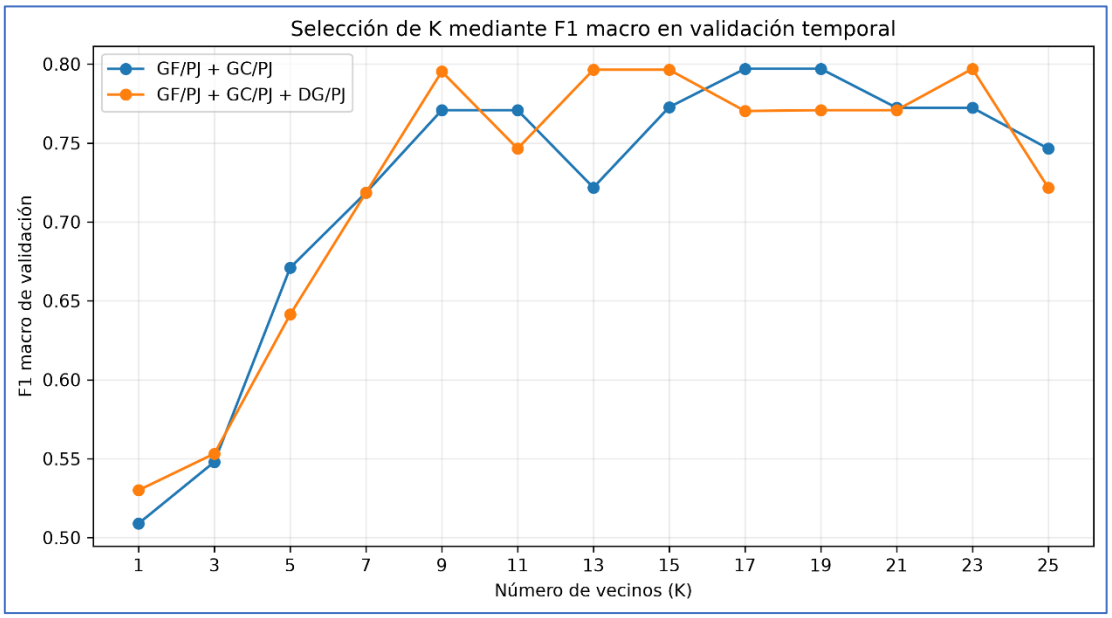


A primera vista, la gráfica muestra una distribución completamente uniforme: cada una de las cuatro zonas contiene 75 registros, equivalentes al 25 % del total. Aunque podría parecer que esto indica una distribución equilibrada de los equipos según su rendimiento, en realidad es una consecuencia de cómo construimos nuestras categorías. Al analizar 15 temporadas y dividir las posiciones en cuatro grupos de cinco lugares, cada zona reúne exactamente la misma cantidad de registros.

Este resultado es importante porque nos permite comenzar el análisis con clases igualmente representadas. De esta manera, ninguna zona tiene una ventaja numérica sobre las demás por contar con más ejemplos durante el entrenamiento del modelo. Sin embargo, debemos tener presente que una distribución equilibrada no significa que las cuatro categorías sean igual de fáciles de clasificar. Aunque cada una contiene 75 registros, las características ofensivas y defensivas de sus equipos pueden parecerse a las de otras zonas, lo que podría provocar errores en el modelo.

Por lo tanto, esta gráfica cumple principalmente una función de comprobación de nuestros datos, más que de explicación del comportamiento futbolístico de LaLiga. No nos permite concluir que exista un equilibrio competitivo entre los equipos ni que las diferencias de rendimiento sean pequeñas o grandes. Lo que sí nos confirma es que las cuatro categorías tienen la misma representación, por lo que el siguiente paso será comprobar si las estadísticas seleccionadas permiten distinguirlas correctamente.

Selección del número de vecinos



Para construir un modelo KNN, no basta con elegir el algoritmo; también debemos determinar cuántos vecinos se utilizarán para clasificar cada equipo. Un valor de (K) demasiado pequeño puede hacer que el resultado dependa excesivamente de unos cuantos registros, mientras que uno demasiado grande puede incorporar equipos con características menos parecidas. Por ello, probamos distintos valores impares de (K), entre 1 y 25, y comparamos su desempeño mediante el F1 macro en las dos temporadas reservadas para validación.

En el modelo base, los mejores resultados se obtuvieron con (K=17) y (K=19), ambos con un F1 macro de aproximadamente 0.797. Como los dos valores empataron en esta métrica, utilizamos la exactitud como segundo criterio y, posteriormente, el menor valor de (K) como desempate. De esta manera, seleccionamos (K=17). En el modelo alternativo, que también incorpora la diferencia de goles por partido, se eligió (K=23).

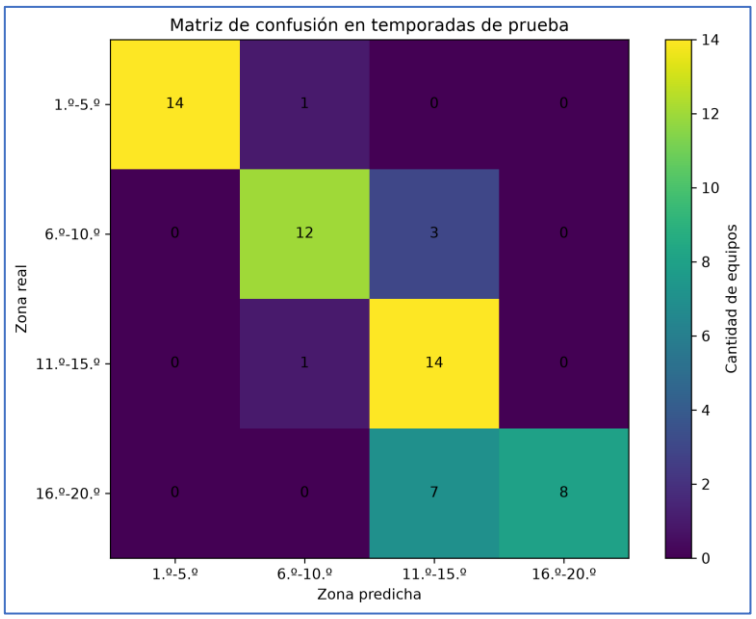
La gráfica permite observar que la selección de (K) no depende únicamente de encontrar el valor más alto, sino de comparar cómo responde el modelo ante diferentes cantidades de vecinos. Además, que varios valores obtengan resultados similares sugiere que, durante la validación, el desempeño no estuvo ligado exclusivamente a una configuración específica. Sin embargo, esto no garantiza que todos esos valores se comporten igual ante temporadas nuevas, por lo que la comparación definitiva debe realizarse con los datos de prueba que mantuvimos separados.

Es importante recordar que esta gráfica corresponde a la validación, no a la evaluación final. Su función es ayudarnos a seleccionar los parámetros antes de medir el desempeño del modelo en las temporadas 2023-24, 2024-25 y 2025-26. Así evitamos elegir el valor de (K) basándonos en los mismos datos con los que posteriormente evaluaremos sus resultados.

Evaluación del modelo de clasificación

A partir de aquí ya no buscamos comprobar cómo se distribuyen los equipos ni qué parámetros conviene utilizar, sino determinar qué tan bien puede el modelo reconocer la zona en la que termina cada equipo. Para ello, analizaremos los resultados obtenidos con las tres temporadas reservadas para la prueba final y compararemos el modelo base con la alternativa que incorpora la diferencia de goles por partido.

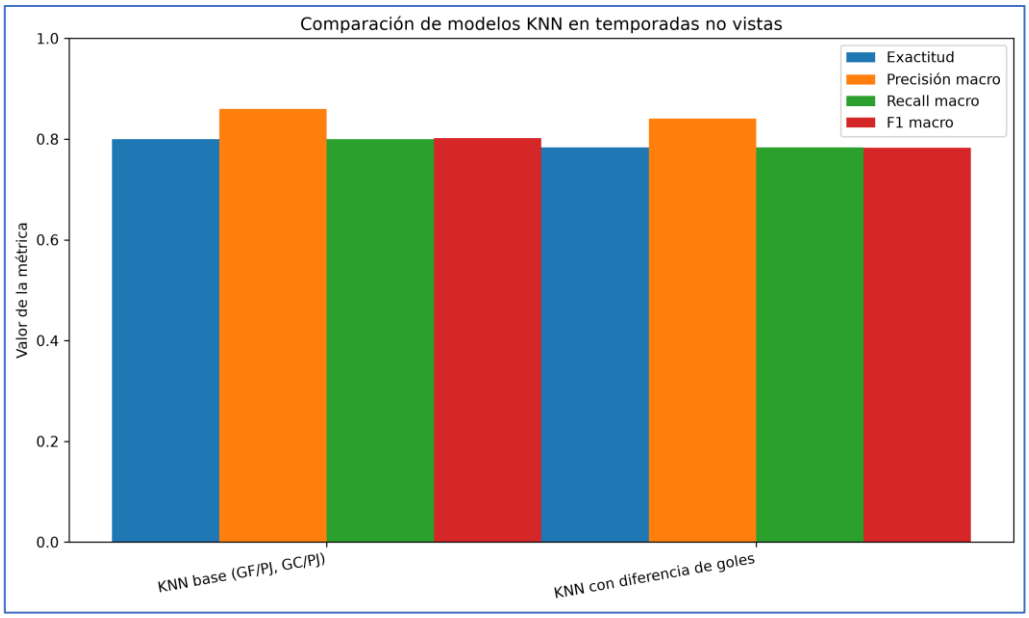
La comparación es importante porque, desde una perspectiva futbolística, marcar más goles y recibir menos suelen ser características asociadas con un mejor rendimiento. Sin embargo, debemos comprobar si añadir la diferencia de goles aporta información suficiente para mejorar la clasificación o si las variables originales ya permiten identificar patrones similares.



Esta matriz de confusión nos permite observar no solamente cuántos equipos fueron clasificados correctamente, sino también hacia qué zonas se desviaron aquellos que el modelo no logró identificar. En las tres temporadas de prueba, el modelo base clasificó correctamente 48 de los 60 registros, lo que equivale a una exactitud del 80 %. Aunque el resultado indica que las estadísticas ofensivas y defensivas contienen información útil para reconocer la posición final de los equipos, también muestra que estas características no permiten distinguir todas las zonas con la misma facilidad.

Uno de los aspectos más interesantes es la dificultad para reconocer a los equipos de la zona del decimosexto al vigésimo lugar. De acuerdo con la matriz, siete equipos de esta categoría fueron clasificados en la zona del undécimo al decimoquinto puesto. Desde una perspectiva futbolística, esto resulta comprensible: los equipos que terminan cerca de la parte baja pueden presentar registros goleadores similares, aunque sus resultados acumulados terminen colocándolos en posiciones diferentes. Una diferencia relativamente pequeña en puntos puede separar a dos equipos con estadísticas ofensivas y defensivas parecidas.

En cambio, el modelo mostró un mejor reconocimiento de las zonas superiores e intermedias. Esto sugiere que los promedios de goles pueden servir para identificar determinados perfiles de rendimiento, aunque pierden capacidad de distinción cuando las características de dos categorías se superponen. Debemos recordar que la matriz representa únicamente las temporadas evaluadas, por lo que sus resultados no garantizan el mismo desempeño en cualquier temporada futura.



Para comprobar si incorporar la diferencia de goles por partido mejora la clasificación, comparamos las métricas del modelo base con las del modelo alternativo. Los resultados fueron los siguientes:

Métrica	**Modelo base**	**Modelo alternativo**
Exactitud	80.00 %	78.33 %
Precisión macro	86.01 %	84.07 %
Recall macro	80.00 %	78.33 %
F1 macro	80.17 %	78.32 %

El modelo base obtuvo mejores resultados en las cuatro métricas. En términos prácticos, clasificó correctamente 48 de los 60 registros, mientras que el modelo alternativo acertó en 47. Por tanto, añadir la diferencia de goles no produjo la mejora que podríamos haber esperado inicialmente.

Una posible explicación es que la diferencia de goles se calcula a partir de los goles a favor y en contra, por lo que no incorpora información completamente independiente. Aunque resume el balance entre ambas variables en un solo indicador, también puede resultar redundante para un algoritmo que ya considera las dos características originales. En este experimento, esa variable adicional no ayudó a separar mejor las categorías.

La diferencia entre los modelos es relativamente pequeña, por lo que no sería adecuado concluir que la diferencia de goles carece de utilidad en cualquier análisis de fútbol. Lo que podemos afirmar es que, con las variables utilizadas, la división temporal y las temporadas evaluadas, el modelo base obtuvo un desempeño ligeramente superior. Esto respalda la elección de una representación más sencilla sin añadir una variable que, en esta prueba, no mejoró los resultados.

En conjunto, la evaluación muestra que KNN puede reconocer correctamente una proporción considerable de las zonas finales de LaLiga utilizando únicamente estadísticas goleadoras. Sin embargo, los errores observados, especialmente entre las dos zonas inferiores, nos recuerdan que la clasificación final también puede depender de otros factores que no están representados en el modelo, como la regularidad durante la temporada o los resultados en partidos específicos. Estos elementos quedan fuera del alcance de las variables seleccionadas y ayudan a explicar por qué un rendimiento estadístico similar no siempre conduce a la misma posición final.

Los resultados obtenidos muestran que las estadísticas ofensivas y defensivas permiten reconocer, con un nivel de acierto considerable, la zona en la que terminan los equipos de LaLiga. El modelo KNN base, utilizando los goles a favor y en contra por partido, clasificó correctamente 48 de los 60 registros de las tres temporadas de prueba, alcanzando una exactitud del 80 %. Este resultado indica que ambas variables contienen información útil para distinguir los perfiles de los equipos, aunque no son suficientes para explicar por completo las diferencias entre sus posiciones finales.

Una de las observaciones más interesantes fue la dificultad para distinguir a los equipos de la zona baja. Siete de los que terminaron entre los puestos 16 y 20 fueron clasificados en la zona del 11 al 15. Desde una perspectiva futbolística, esto puede relacionarse con la similitud que existe entre algunos equipos que compiten por mantenerse en Primera División y aquellos que terminan en posiciones intermedias. Dos clubes pueden presentar promedios de goles semejantes y, aun así, acumular cantidades diferentes de puntos. La distribución de sus victorias, empates y derrotas, así como su regularidad durante la competición, puede marcar diferencias importantes en la clasificación final. Aunque estos factores no se evaluaron directamente, ayudan a comprender por qué las estadísticas seleccionadas no siempre permiten separar con claridad a equipos que terminan en zonas cercanas.

Por otra parte, incorporar la diferencia de goles por partido no mejoró el desempeño del modelo. La alternativa alcanzó una exactitud del 78.33 %, frente al 80 % del modelo base. Esto sugiere que, en esta configuración, añadir una variable derivada de los goles a favor y en contra no aportó información suficiente para mejorar la clasificación. El resultado también demuestra la importancia de evaluar las variables en lugar de asumir que una mayor cantidad de información necesariamente produce mejores resultados.

En el contexto general de nuestra investigación sobre la estructura competitiva de LaLiga, esta práctica permitió pasar de la identificación de patrones a comprobar si podían utilizarse para clasificar a los equipos. Los análisis descriptivos y estadísticos anteriores nos ayudaron a reconocer diferencias entre las zonas de la tabla, mientras que el modelo KNN permitió evaluar hasta qué punto algunas de esas diferencias podían identificarse mediante sus características goleadoras. De esta forma, la clasificación complementa los resultados anteriores al mostrar que los patrones observados tienen utilidad para distinguir perfiles de rendimiento, aunque todavía dejan aspectos del comportamiento de los equipos sin explicar.

En general, consideramos que los resultados fueron satisfactorios para el objetivo de la actividad, ya que el modelo base clasificó correctamente ocho de cada diez registros de temporadas que no participaron en su entrenamiento ni en la selección de sus parámetros. Sin embargo, es importante señalar que se trata de una clasificación retrospectiva: utilizamos estadísticas acumuladas de temporadas completas para reconocer la zona final de cada equipo, no para anticipar desde el inicio dónde terminaría. Como posible continuación, sería interesante incorporar variables relacionadas con los puntos por partido, la regularidad o el rendimiento como local y visitante, y comprobar si permiten distinguir mejor a los equipos con estadísticas goleadoras similares.